

Uniwersytet Warszawski
Wydział Nauk Ekonomicznych

Monika Kaczan
410998

Mateusz Domaradzki
410089

Analiza porównawcza ryzyka

**Projekt zaliczeniowy na przedmiot
Zaawansowana Analiza Szeregów Czasowych**

Praca wykonana pod kierunkiem
dr Anety Dzik-Walczak

Warszawa, czerwiec 2023

Wstęp

Celem niniejszego projektu jest analiza porównawcza ryzyka rozumianego jako oszacowanie funkcji warunkowej wariancji w modelach klasy GARCH. W ramach badania utworzyliśmy portfel złożony z czterech kryptowalut. Po wstępnej analizie danych zbudowaliśmy siedem modeli należących do klasy GARCH i porównaliśmy ich wyniki. Najlepszy model został następnie wykorzystany do oszacowania funkcji warunkowej wariancji oraz oszacowania wartości narażonej na ryzyko w okresie out-of-sample.


Dane

Zgodnie z założeniami projektu, do stworzenia portfela wybraliśmy cztery kryptowaluty, których pierwsze litery nazw odpowiadały pierwszym literom naszych imion i nazwisk: Polygon (MATIC), Dash (DASH), Maker (MKR) oraz KuCoin (KCS). Na ich podstawie stworzyliśmy portfel, w którym każdego dnia udziały procentowe cen zamknięcia każdej z kryptowalut były proporcjonalne do ich kapitalizacji rynkowej (ang. *market-cap-weighted portfolio*).

Jako okres badawczy przyjęliśmy ostatnie 2,5 roku od 1 stycznia 2021 do daty pobrania danych tj. 20 czerwca 2023. Tym samym nasza próba składała się z 731 obserwacji. Wybór okresu był podyktowany dostępnością danych dla poszczególnych walut, a także chęcią uzyskania odpowiedniej liczby obserwacji do przeprowadzenia modelowania przy jednoczesnym zachowaniu jej aktualności. Jako okres in-sample zostanie potraktowane pierwsze 631 obserwacji, a jako okres out-of-sample kolejne 100.

Na Rysunku 1 przedstawiliśmy wykresy kapitalizacji rynkowej, a tym samym udziału procentowego w portfelu każdej z kryptowalut w czasie. Widzimy, że od II kwartału 2021 roku kapitalizacja MATIC znacząco wzrosła i w dużym stopniu przeważa nad innymi kryptowalutami. Udziały DASH, MKR i KCS w portfelu są nikłe. Możemy więc powiedzieć, że nasz portfel jest słabo zdywersyfikowany.

Rysunek 1. Kapitalizacja rynkowa wybranych kryptowalut

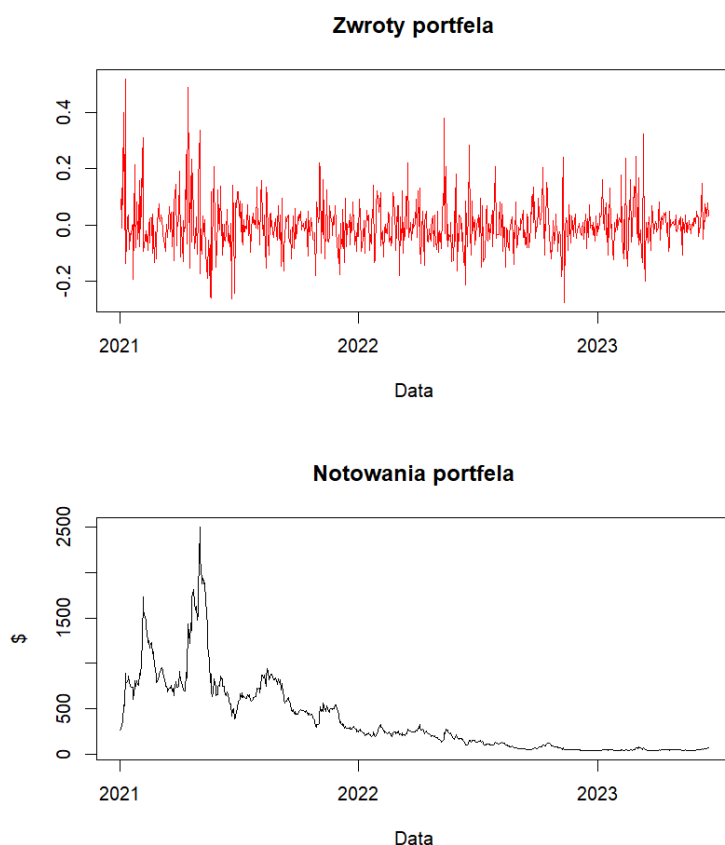


Źródło: Opracowanie własne

Wstępna analiza danych

W pierwszej kolejności obliczyliśmy ciągłe zwroty, na których będziemy przeprowadzać dalszą analizę. Rysunek 2 przedstawia wykresy notowań i zwrotów utworzonego przez nas portfela. Na podstawie wykresu notowań widzimy, że notowania naszego portfela były wysokie i charakteryzowały się wysoką wariancją w pierwszej połowie 2021 roku, natomiast później były mniej zmienne i małe. Z pewnością nie jest to więc szereg stacjonarny. Na podstawie wykresu zwrotów możemy zaobserwować, że charakteryzują się one zjawiskiem grupowania wariancji - okresy małych jak i dużych zmian kursów mają tendencję do występowania seriami.

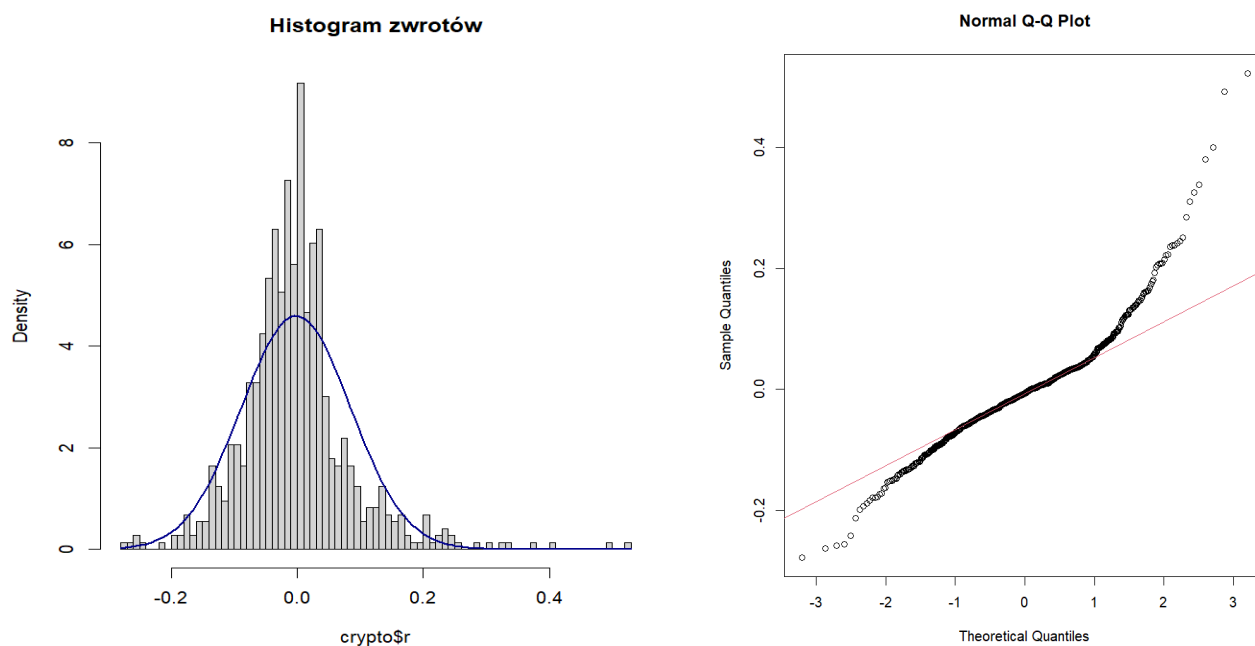
Rysunek 2. Charakterystyka portfela – zwroty oraz notowania



Źródło: Opracowanie własne

Na Rysunku 3 został przedstawiony histogram zwrotów portfela oraz wykres QQplot. Widzimy, że rozkład zwrotów jest prawo skośny, chociaż poza tym może przypominać rozkład normalny. Brakuje m.in. wysokiego szczytu funkcji gęstości charakterystycznego dla rozkładu leptokurtycznego. W formalnym teście Jacque-Bera odrzuciliśmy H_0 o normalności rozkładu zwrotów. Podobnie na Rysunku 3 przedstawiającym wykres QQplot widzimy, że na ogonach nasza próba odchodzi od rozkładu normalnego.

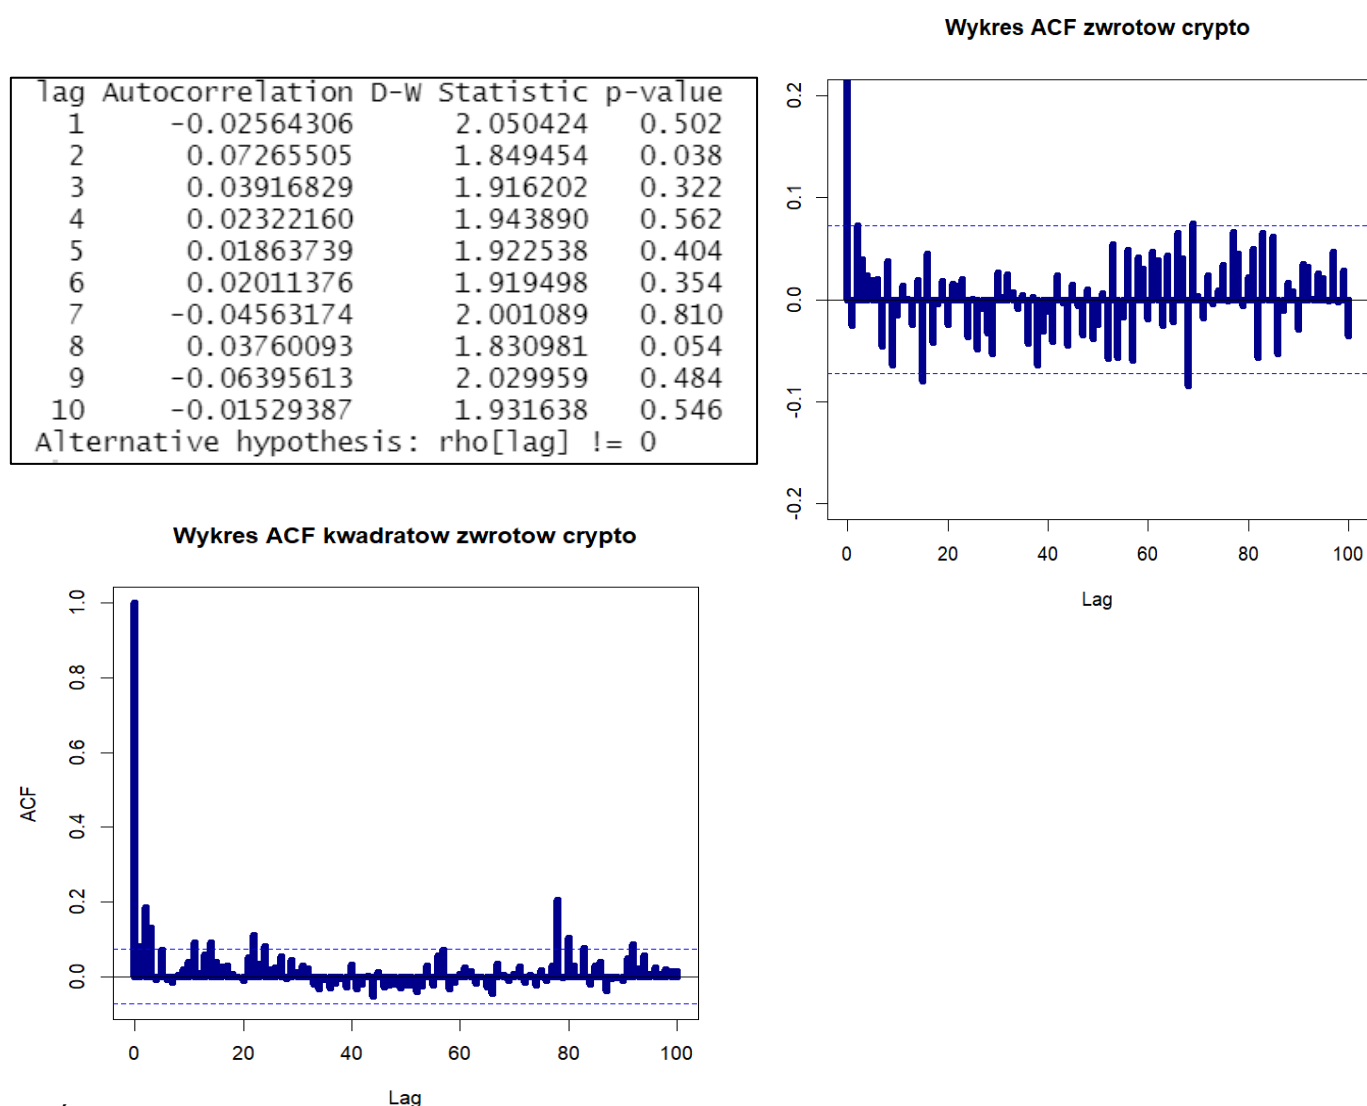
Rysunek 3. Histogram zwrotów portfela oraz wykres QQplot.



Źródło: Opracowanie własne

Następnie przeanalizowaliśmy wykresy ACF zwrotów oraz kwadratów zwrotów na Rysunku 4. Na wykresie ACF zwrotów widzimy kilka istotnych wartości, co może wskazywać na pewne problemy z autokorelacją. Potwierdza to również formalny test Durbina-Watsona, gdzie na 10% poziomie istotności nie możemy odrzucić H_0 o występowaniu autokorelacji dla 2 i 8 opóźnień.

Rysunek 4. Statystyka DW, wartości ACF dla zwrotów oraz ich kwadratów



Źródło: Opracowanie własne

Na wykresie ACF kwadratów zwrotów widzimy kilka istotnych wartości, jednak nie jest ich dużo i ciężko powiedzieć, aby wygasały. Na podstawie wykresów możemy więc tylko przypuszczać, że występują jakieś efekty ARCH. Formalny test LM na występowanie efektów ARCH potwierdził jednak, że takie efekty są obecne (bardzo silnie odrzucamy H_0 o braku efektów ARCH). Możemy więc przejść do modelowania.

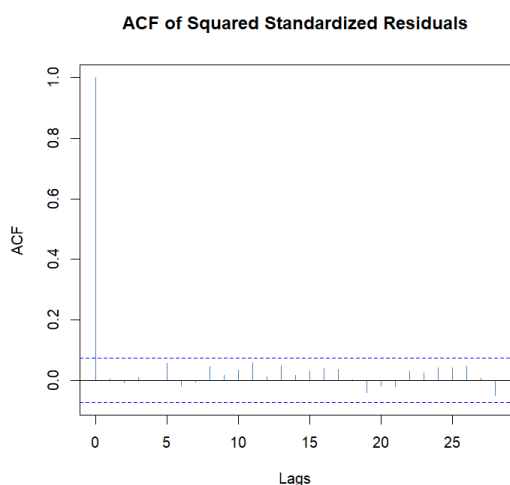

Modele ARCH i GARCH

Na początku przetestowaliśmy najprostszy model ARCH(1) jako benchmark. Stała w równaniu średniej okazała się nieistotna, więc usunęliśmy ją z modelu. Testy diagnostyczne wykazały, że reszty w modelu nie mają rozkładu normalnego. Jednak nie udało się nam usunąć efektów ARCH - w teście LM odrzucaliśmy H_0 o braku efektów ARCH.

W związku z tym zwiększyliśmy liczbę opóźnień autoregresyjnych do 2, a później 3 i ponownie oszacowaliśmy model ARCH. Dopiero w modelu ARCH(3) udało nam się usunąć efekty ARCH. Reszty w modelu nadal nie miały rozkładu normalnego (Test Jarque-Bera), jednak jak wspomnieliśmy udało nam się usunąć efekty ARCH (LM Arch Test). W stosunku do ARCH(1), poprawiliśmy też znacząco wartości kryteriów informacyjnych.

Rysunek 5. Wyniki ARCH(1).

Error Analysis:				
	Estimate	Std. Error	t value	Pr(> t)
omega	0.0035511	0.0003626	9.795	< 2e-16 ***
alpha1	0.1351884	0.0481637	2.807	0.005003 **
alpha2	0.1783485	0.0519892	3.430	0.000602 ***
alpha3	0.2664112	0.0705343	3.777	0.000159 ***
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1				
Log Likelihood:				
802.4809 normalized: 1.099289				
Description:				
Wed Jun 28 16:21:32 2023 by user: Monika				
Standardised Residuals Tests:				
			Statistic	p-Value
Jarque-Bera Test	R	Chi^2	194.9277	0
Shapiro-Wilk Test	R	W	0.960989	5.068901e-13
Ljung-Box Test	R	Q(10)	15.61124	0.1113152
Ljung-Box Test	R	Q(15)	18.83433	0.2213396
Ljung-Box Test	R	Q(20)	22.32663	0.3230531
Ljung-Box Test	R^2	Q(10)	5.257305	0.8733403
Ljung-Box Test	R^2	Q(15)	10.55754	0.7832829
Ljung-Box Test	R^2	Q(20)	14.25325	0.8174271
LM Arch Test	R	TR^2	9.170174	0.6883307
Information Criterion Statistics:				
	AIC	BIC	SIC	HQIC
	-2.187619	-2.162452	-2.187678	-2.177909



Źródło: Opracowanie własne

Analizując korelogramy standaryzowanych reszt i kwadratów standaryzowanych reszt na Rysunku 5, obserwujemy, że wszystkie wartości na obu wykresach są (w przybliżeniu) statystycznie nieistotne. Oznacza to, że udało nam się wyeliminować autokorelacje i efekty ARCH.

W dalszej kolejności oszacowaliśmy modele z rodziny GARCH, wychodząc od modelu GARCH(1,1). Podobnie jak w przypadku modeli ARCH, szukaliśmy wśród takiej specyfikacji, w której wszystkie parametry były statystycznie istotne na poziomie 10% oraz udało się wyeliminować efekty ARCH. Następnie wybraliśmy model o najniższej wartości kryteriów informacyjnych. W naszym przypadku okazało się, że wystarczył model GARCH(1,1).

Rysunek 6. Wyniki GARCH(1,1)

```

Error Analysis:
      Estimate Std. Error t value Pr(>|t|)
omega  0.0006131  0.0001887   3.249  0.00116 **
alpha1  0.2278967  0.0487514   4.675  2.94e-06 ***
beta1   0.7160426  0.0501628  14.274  < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1


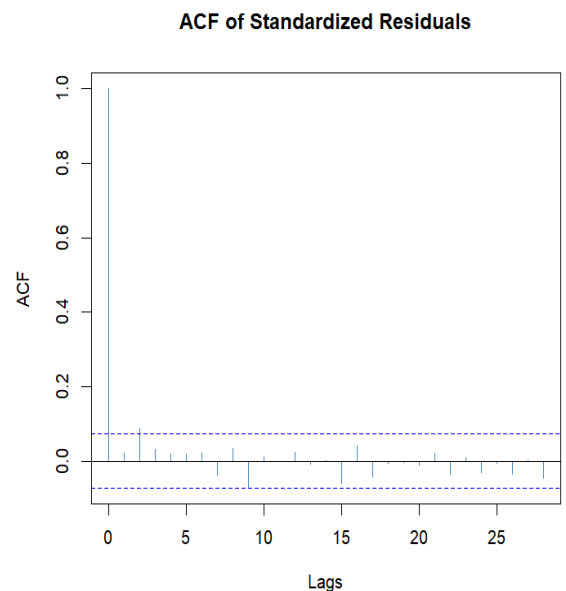
Log Likelihood:
803.2656 normalized: 1.100364

Description:
Wed Jun 28 17:12:42 2023 by user: Monika

Standardised Residuals Tests:
      Statistic p-Value
Jarque-Bera Test R Chi^2 230.1713 0
Shapiro-Wilk Test R W 0.9593117 2.38825e-13
Ljung-Box Test R Q(10) 13.15616 0.2150714
Ljung-Box Test R Q(15) 16.31753 0.3612679
Ljung-Box Test R Q(20) 19.13738 0.5129127
Ljung-Box Test RA^2 Q(10) 9.913565 0.4481091
Ljung-Box Test RA^2 Q(15) 14.18145 0.5118141
Ljung-Box Test RA^2 Q(20) 15.57266 0.7427567
LM Arch Test R TR^2 12.10902 0.4369641

Information Criterion Statistics:
      AIC BIC SIC HQIC
-2.192509 -2.173633 -2.192542 -2.185226

```



Źródło: Opracowanie własne

Również w przypadku modelu GARCH(1,1) przyjrzelśmy się korelogramom standaryzowanych reszt i kwadratów standaryzowanych reszt na Rysunku 6. Ponownie wykresy wskazują, że udało nam się wyeliminować autokorelacje i efekty ARCH, jednak rozkład reszt nie jest normalny.


Rozszerzenia modeli GARCH

Jak widzimy powyżej, Modele wciąż można ulepszyć np. poprzez uzyskanie rozkładu normalnego reszt. Z tego powodu do dalszego badania zostaną rozważone 3 rozszerzenia modelu GARCH. Chodzi mianowicie gjr-GARCH, tGARCH oraz GARCH-t. Najlepszy model do prognozowania oraz wyjaśniania naszych danych zostanie wybrany za pomocą kryteriów informacyjnych MAIC.

Model GARCH-t różni się tym od modelu GARCH, że rozkład jego składnika losowego przyjmuje rozkład t-studenta. Jest to uzasadnione ze względu na wcześniej obserwowane grupowanie się wariancji co wskazuje na potrzebę użycia rozkładu t-studenta który charakteryzuje się “grubszymi ogonkami rozkładu” czyli większą kurtozą. Stąd dalsze wyniki będą dotyczyły modelu GARCH-t (1,1)

Rysunek 7. Wyniki dla GARCH-t(1,1)

* GARCH Model Fit *					Weighted Ljung-Box Test on Standardized Squared Residuals				
-----					-----				
Conditional Variance Dynamics					statistic p-value				
-----					Lag[1]	0.5972	0.4396		
					Lag[2*(p+q)+(p+q)-1][5]	3.7633	0.2851		
GARCH Model : sGARCH(1,1)					Lag[4*(p+q)+(p+q)-1][9]	6.1692	0.2792		
Mean Model : ARFIMA(0,0,0)					d.o.f=2				
Distribution : std									
Optimal Parameters					Weighted ARCH LM Tests				
-----					-----				
	Estimate	Std. Error	t value	Pr(> t)		Statistic	Shape	Scale	P-Value
omega	0.000646	0.000329	1.9625	0.049701	ARCH Lag[3]	3.882	0.500	2.000	0.04881
alpha1	0.204448	0.072759	2.8099	0.004956	ARCH Lag[5]	5.172	1.440	1.667	0.09378
beta1	0.747150	0.077756	9.6090	0.000000	ARCH Lag[7]	6.576	2.315	1.543	0.10697
shape	3.779299	0.589396	6.4122	0.000000					
Robust Standard Errors:									
	Estimate	Std. Error	t value	Pr(> t)					
omega	0.000646	0.000459	1.4076	0.159262					
alpha1	0.204448	0.082200	2.4872	0.012876					
beta1	0.747150	0.104541	7.1469	0.000000					
shape	3.779299	0.519097	7.2805	0.000000					



Źródło: Opracowanie własne


Jak widać na Rysunku 7 problem zaczyna się już z eliminacją efektu ARCH. Co prawda wartości nie osiągają wartości 0, lecz są całkiem bliskie. Patrząc na test Ljunga-Boxa udało się natomiast wyeliminować autokorelację reszt. Zwracając jednak uwagę na parametry modelu, trzeba zauważyć, że omega jest nieistotna statystycznie. Zatem odrzucamy hipotezę zerową o korelacji dla kwadratów wystandaryzowanych reszt.

Patrząc na Rysunek 7 nie udało się wyeliminować autokorelacji reszt dla pojedynczej wartości dla drugiego okresu. Model nadal można zatem ulepszyć lub sprawdzić czy uzyskane kryteria informacyjne dla innych modeli nie są niższe.

Kolejnym zaproponowanym modelem będzie tGARCH(1,1). Jego wybór podyktowany został tym, że dostosowuje się lepiej do szoków niż zwykły model GARCH. Stąd, jeśli bada się zjawisko takie jak kryptowaluty, o dużej zmienności, warto go rozważyć.

Rysunek 8. Wyniki tGARCH(1,1)

Conditional Variance Dynamics					Weighted Ljung-Box Test on Standardized Residuals		
-----					-----		
GARCH Model	: fGARCH(1,1)				statistic p-value		
fGARCH Sub-Model	: TGARCH				Lag[1]	0.1474	0.7010
Mean Model	: ARFIMA(0,0,0)				Lag[2*(p+q)+(p+q)-1][2]	2.4031	0.2038
Distribution	: norm				Lag[4*(p+q)+(p+q)-1][5]	5.1553	0.1412
Optimal Parameters					d.o.f=0		
-----					H0 : No serial correlation		
	Estimate	Std. Error	t value	Pr(> t)	Weighted Ljung-Box Test on Standardized Squared Residuals		
omega	0.007329	0.002478	2.9575	0.003102	-----		
alpha1	0.218313	0.034290	6.3666	0.000000	statistic p-value		
beta1	0.759379	0.043995	17.2608	0.000000	Lag[1]	0.493	0.48258
eta11	-0.221813	0.085914	-2.5818	0.009829	Lag[2*(p+q)+(p+q)-1][5]	7.513	0.03888
Robust Standard Errors:					Lag[4*(p+q)+(p+q)-1][9]	11.097	0.02893
	Estimate	Std. Error	t value	Pr(> t)	d.o.f=2		
omega	0.007329	0.004180	1.7532	0.079576	Weighted ARCH LM Tests		
alpha1	0.218313	0.053295	4.0963	0.000042	-----		
beta1	0.759379	0.075708	10.0304	0.000000	Statistic Shape Scale P-Value		
eta11	-0.221813	0.111644	-1.9868	0.046947	ARCH Lag[3]	10.22	0.500 2.000 0.001387
LogLikelihood : 804.985					ARCH Lag[5]	11.74	1.440 1.667 0.002468
					ARCH Lag[7]	13.06	2.315 1.543 0.003445




Źródło: Opracowanie własne

Patrząc na korelogram na Rysunku 8 modelu tGARCH(1,1) widać, że standaryzowane reszty mają tendencję do autokorelacji co potwierdza wyniki testu Q-Ljunga Boxa uzyskanego wyżej. Dlatego ze względu na dość słabe wyniki modelu tGARCH(1,1) zostanie także sprawdzona jego inna specyfikacja mianowicie tGARCH(2,1).

Rysunek 9. Wyniki tGARCH(2,1)

Conditional Variance Dynamics					Weighted Ljung-Box Test on Standardized Residuals		
-----					-----		
GARCH Model	: fGARCH(2,1)					statistic	p-value
fGARCH Sub-Model	: TGARCH				Lag[1]	0.3067	0.5797
Mean Model	: ARFIMA(0,0,0)				Lag[2*(p+q)+(p+q)-1][2]	2.6222	0.1777
Distribution	: norm				Lag[4*(p+q)+(p+q)-1][5]	4.9542	0.1568
Optimal Parameters					d.o.f=0		
-----					H0 : No serial correlation		
	Estimate	Std. Error	t value	Pr(> t)	Weighted Ljung-Box Test on Standardized Squared Residuals		
omega	0.008625	0.000986	8.7473	0.000000	-----		
alpha1	0.167870	0.034915	4.8080	0.000002		statistic	p-value
alpha2	0.149386	0.006227	23.9917	0.000000	Lag[1]	0.07011	0.7912
beta1	0.639175	0.032131	19.8926	0.000000	Lag[2*(p+q)+(p+q)-1][8]	5.26346	0.3183
eta11	-0.573113	0.234458	-2.4444	0.014509	Lag[4*(p+q)+(p+q)-1][14]	8.50300	0.3297
eta12	-0.273883	0.164275	-1.6672	0.095470	d.o.f=3		
Robust Standard Errors:					Weighted ARCH LM Tests		
	Estimate	Std. Error	t value	Pr(> t)	-----		
omega	0.008625	0.001384	6.2331	0.000000		Statistic	Shape
alpha1	0.167870	0.056192	2.9874	0.002813	ARCH Lag[4]	1.461	0.500
alpha2	0.149386	0.015491	9.6437	0.000000	ARCH Lag[6]	3.516	1.461
beta1	0.639175	0.027728	23.0514	0.000000	ARCH Lag[8]	5.523	2.368
eta11	-0.573113	0.310042	-1.8485	0.064530		Scale	P-Value
eta12	-0.273883	0.229990	-1.1908	0.233714		2.000	0.2268
LogLikelihood : 810.5015						1.711	0.2394
						1.583	0.1982




Źródło: Opracowanie własne

Patrząc na Rysunek 9, dzięki zmianie specyfikacji z tGARCH(1,1) na tGARCH(2,1) udało się wyeliminować wiele negatywnych wyników. Mianowicie dla modelu tGARCH(2,1) test LM ARCH wskazuje na brak efektów ARCH a test Q-Ljunga Boxa wskazuje na brak autokorelacji wśród reszt.

Podobnie jak tGARCH, gjr-GARCH cechuje się tym, że w lepszym stopniu dostosowuje się do gwałtownych zmian wartości portfela.

Rysunek 10. Wyniki gjr-GARCH(1,1)

Conditional Variance Dynamics					Weighted Ljung-Box Test on Standardized Residuals				
-----					-----				
GARCH Model	: gjrGARCH(1,1)				statistic p-value				
Mean Model	: ARFIMA(0,0,0)				Lag[1]	0.3809	0.5371		
Distribution	: norm				Lag[2*(p+q)+(p+q)-1][2]	2.9954	0.1407		
Optimal Parameters					Lag[4*(p+q)+(p+q)-1][5]	5.1897	0.1386		
					d.o.f=0				
					H0 : No serial correlation				
-----					-----				
	Estimate	Std. Error	t value	Pr(> t)	Weighted Ljung-Box Test on Standardized Squared Residuals				
omega	0.000640	0.000198	3.2249	0.001260	-----				
alpha1	0.269967	0.065824	4.1013	0.000041	statistic p-value				
beta1	0.713017	0.052516	13.5772	0.000000	Lag[1]	1.172	0.2789		
gamma1	-0.088482	0.064505	-1.3717	0.170155	Lag[2*(p+q)+(p+q)-1][5]	3.981	0.2564		
Robust Standard Errors:					Lag[4*(p+q)+(p+q)-1][9]	6.561	0.2388		
	Estimate	Std. Error	t value	Pr(> t)	d.o.f=2				
omega	0.000640	0.000312	2.04794	0.040566	Weighted ARCH LM Tests				
alpha1	0.269967	0.102755	2.62729	0.008607	-----				
beta1	0.713017	0.081513	8.74724	0.000000	Statistic Shape Scale P-Value				
gamma1	-0.088482	0.088933	-0.99493	0.319770	ARCH Lag[3]	3.565	0.500	2.000	0.0590
LogLikelihood : 804.2198					ARCH Lag[5]	5.022	1.440	1.667	0.1016
					ARCH Lag[7]	6.677	2.315	1.543	0.1018



Źródło: Opracowanie własne

Jak widać na Rysunku 10 parametr modelu gamma1 jest nieistotny statystycznie. Mimo to model gjr-GARCH(1,1) zdołał wyeliminować efekty ARCH patrząc na wyniki modelu ARCH LM, oraz wyeliminować autokorelację wśród reszt (test Q-Ljunga-Boxa)

Na Rysunku 10 zostały pokazane wartości ACF dla modelu gjr-GARCH(1,1). Ponownie widać, że słupek dla 2 okresu przekracza dopuszczalną wartość. Stąd zostanie podjęta próba zmiany wartości specyfikacji gjr-GARCH(1,1). Niestety po wielu próbach zmiany specyfikacji, model nie uległ ulepszeniu, stąd nie zostaną zaprezentowane inne dla niego wyniki.

Ostatecznie do porównania wyników posłużą uzyskane kryteria informacyjne. Najlepszy model zostanie wybrany poprzez ich minimalizację.

Tabela 1. Wyniki MAIC dla wybranych modeli

	ARCH(1)	ARCH(3)	GARCH(1, 1)	GARCH(3, 1)	GARCH- t(1,1)	T- GARCH(2, 1)	gjr- GARCH(1, 1)
Akaike	-2,07	-2,19	-2,19	-2,19	-2,29	-2,2	-2,2
Bayes	2,05	-2,16	-2,17	-2,15	-2,27	-2,17	-2,17
Shibata	-2,07	-2,19	-2,19	-2,19	-2,29	-2,2	-2,2
Hannan- Quinn	-2,06	-2,18	-2,19	-2,18	-2,28	-2,19	-2,19

Źródło: Opracowanie własne


Patrząc na tabelę 1, najmniejsze wartości wszystkich kryteriów informacyjnych przyjmuje GARCH-t(1,1). Sprawdził się on najlepiej do wytłumaczenia zmienności badanego szeregu czasowego. Zdecydowanie najgorszą wersją okazał się ARCH(1).

Wartość warunkowej wariancji

Do oszacowania funkcji warunkowej wariancji wykorzystaliśmy model GARCH(1,1), najlepszy model GARCH bez rozszerzeń.

Rysunek 11 przedstawia wykres oszacowań i prognoz warunkowej wariancji w 100 dniowym okresie. Widzimy, że wykres wariancji warunkowej w długim okresie zbiega do wariancji bezwarunkowej (oznaczonej czerwoną przerywaną linią).

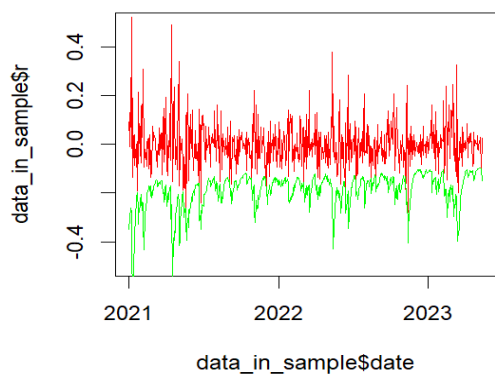
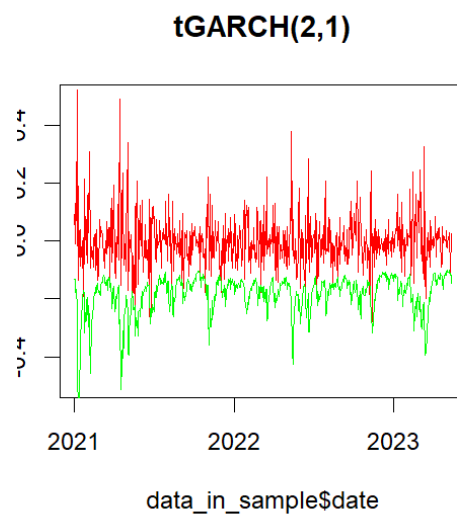


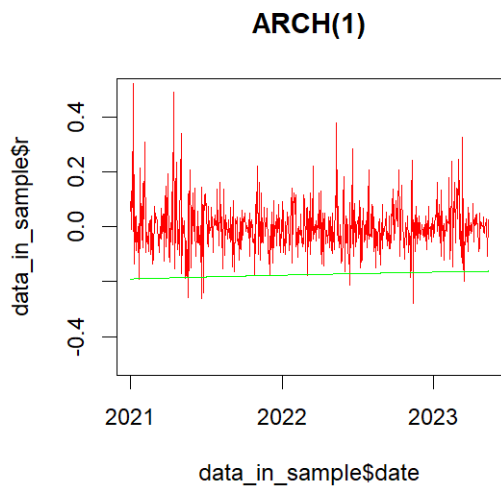
Rysunek 11. Wykres oszacowań i prognoz wariancji warunkowej w długim okresie



VaR (wartość narażona na ryzyko) in-sample

Do policzenia wartości VaR został wybrany 1 kwantyl ($\text{quantile}(0,01)$).

Rysunek 12. Wartości VaR oraz zwrotów akcji dla wybranych modeli



Źródło: Opracowanie własne

Warto także sprawdzić dla ilu procent obserwacji standaryzowane stopy zwrotów przekroczyły wartości VaR

Tabela 2. Procent obserwacji, które przekroczyły wartość VaR

ARCH(1)	1,72%
GARCH(1,1)	1,86%
GARCH-t(1,1)	1,00%
t-GARCH(2,1)	2,00%
gjr-GARCH(1,1)	1,14%


Źródło: Opracowanie własne


Zatem najmniejszy wynik udało się uzyskać dla GARCH-t(1,1), 1% obserwacji przekroczyło poziom VaR.

VaR (wartość narażona na ryzyko) out-of-sample

Zgodnie z wcześniejszymi założeniami, ostatnie 100 obserwacji to próbka out-of-sample. Zostanie dokonana dla nich analiza VaR.

Rysunek 13. Wartość VaR oraz zwrotów akcji dla wybranych modeli





źródło: Opracowanie własne

Również zostanie sprawdzone w jak dużym procencie wartość VaR została przekroczona poprzez pojedyncze stopy zwrotu

Tabela 3. Procent obserwacji, które przekroczyły wartość VaR

ARCH(1)	1%
GARCH(1,1)	2%
GARCH-t(1,1)	1%
t-GARCH(2,1)	1%
gjr-GARCH(1,1)	2%

Źródło: Opracowanie własne

Jak widać w Tabeli 3, procenty są liczbami całkowitymi. Bierze się to z małej liczby obserwacji, a mianowicie 100. Najgorzej poradziły sobie GARCH(1,1) oraz gjr-GARCH(1,1).

Podsumowanie

Projekt podjął analizę portfela złożonego z 4 instrumentów giełdowych, mianowicie kryptowalut. Zostały przeprowadzone testy zarówno na normalność rozkładu oraz występowanie efektów ARCH. Po stwierdzeniu braku rozkładu normalnego oraz obecności efektów ARCH do modelowania szeregów czasowych zostały wybrane modele GARCH oraz ich rozszerzenia. Kryteria informacyjne wskazały, że najlepiej dopasowanym modelem do danych jest GARCH-t(1,1). Pod koniec pracy dokonano także analizy VaR dla próby in-sample oraz out-of-sample.